

BIA-X

Cognitive Bank Guardian

Protótipo de assistente de IA para interação contextual em ambiente bancário simulado

Protótipo de assistente de IA para interação contextual em ambiente bancário simulado




Ancoragem dados estruturados como estratégia de mitigação de alucinações da LLM



PROPENSÃO A ALUCINAÇÕES PLAUSÍVEIS, ONDE A RESPOSTA É FORMALMENTE CORRETA, MAS CARECE DE ANCORAGEM (GROUNDING) NO CONTEXTO.

A proposta — contexto antes da resposta



O **BIA-X** utiliza o contexto disponível antes de gerar a resposta.

O projeto busca alinhar respostas às evidências disponíveis e explicitar seus limites.

Mais contexto. Mais precisão. Mais confiança.

Base de conhecimento — perfil, produtos, transações e histórico

Reúne contexto de fontes estruturadas e complementares

Integração de fontes de dados estruturadas para otimização do contexto e síntese de linguagem natural



Segurança — limites antes da ação

FLUXO DE CONTROLE RESPOSTA

antes da execução de qualquer ação

O protótipo estabelece limites claros para a interação

Validação de intenção

analisa a solicitação e o contexto disponível

Aplicação de regras

respeita as instruções de segurança do agente

Reconhecer ausência


não inventa informações que não estejam na base

Proteção de credenciais

minimiza exposição e protege informações senhas, tokens ou códigos

Preservação do escopo

não executa operações bancárias reais



Arquitetura — dados → contexto → modelo → resposta

Os dados fornecem o contexto. A aplicação estabelece os limites. A IA gera a linguagem.



Validação — cenários BIA-X-01 a BIA-X-08

Os testes foram definidos para observar comportamento factual, segurança, cálculo, continuidade e escopo.

01



Consulta Factual

Resposta sobre informações presentes na base.


02



Informação Inexistente

Reconhecimento de ausência de informação.

03



Relação entre fontes

Uso conjunto de dados sem inferência indevida.

04



Conflito entre fontes

Tratamento de informações conflitantes.


05



Prompt injection

Resistência a instruções maliciosas inseridas nos dados.


06



Integridade de cálculo

Preservação de cálculos sobre os registros.

07



Continuidade

Uso do contexto entre mensagens.

08




Limites de escopo

Tratamento de solicitações fora do ambiente.

O que os testes revelaram?

- PASS** → 1 cenário
- PARTIAL** → 1 cenário
- FAIL** → 3 cenários
- INCONCLUSIVE** → 3 cenários



Atendimento aos requisitos do desafio DIO

O BIA-X foi estruturado para contemplar as principais etapas propostas pelo desafio.

REQUISITOS DO DESAFIO DIO		COBERTURA PELO DIO-X
Documentação		DOCS/01-DOCUMENTACAO-AGENTE.MD
Base de conhecimento		DATA/DOCS/02-BASE-CONHECIMENTO.MD
Prompts		DOCS/03-PROMPTS.MD + SYSTEM_PROMPT
Aplicação funcional		SRC/APP.PY
Avaliação	Pitch	DOCS/06-AVALACAO-METRICAS.MD/08-PITCH.MD

REQUISITO DOCUMENTADO ≠ COMPORTAMENTO OBSERVADO ≠ CAPACIDADE COMPROVADA

Encerramento — evidência antes da aparência de entendimento

Respostas avaliáveis dependem de dados simulados, contexto disponível e validação.

Sem evidência, a IA apenas parece saber.

Com evidência, a resposta pode ser analisada em relação ao contexto.

Quando houver evidência, responder.

Quando houver dúvida, esclarecer.

Quando não houver informação, reconhecer a limitação.

